

Ciencia de Datos para las Finanzas

Introducción a la Ciencia de datos para las Finanzas

César Núñez Cuevas
cnunezc@fen.uchile.cl



¿Cómo entra el Machine Learning acá?

¿Cómo entra el Machine Learning acá?



(c)



(d)

El Enigma de la “Caja Negra” en Modelos Predictivos

La Analogía del Cine: Mystery Boxes

Al igual que las *mystery boxes* de J.J. Abrams, donde el valor radica en el suspenso de lo desconocido, muchos algoritmos avanzados operan sin revelar su lógica interna.

- Ingresamos datos del cliente (Input).
- El modelo genera una predicción (Output).
- **El conflicto:** ¿Cómo confiamos en el resultado si la lógica intermedia permanece oculta en la oscuridad?

El Lado Oscuro del Riesgo

Un modelo sin interpretabilidad es como Darth Vader: posee un poder inmenso y toma decisiones drásticas, pero su criterio es hermético, inflexible y potencialmente peligroso frente a regulaciones bancarias (ej. leyes de no discriminación).

Abriendo la Caja: De la Caja Negra a la Caja Blanca

Para estudiantes y analistas de riesgo, el primer paso en Machine Learning no debe ser un modelo complejo y oculto, sino una estructura transparente.

Modelos de Caja Negra

- Redes Neuronales Profundas o Gradient Boosting.
- Alta precisión matemática.
- Explicabilidad casi nula para el auditor.

Modelos de Caja Blanca (Árboles)

- Reglas lógicas y secuenciales explícitas.
- Cada decisión de crédito deja un rastro auditable.

Los Tres Grandes Paradigmas del Machine Learning

El Machine Learning se clasifica principalmente en tres categorías, según la naturaleza de los datos y la forma en que el algoritmo interactúa con ellos:

Aprendizaje Supervisado

El modelo se entrena con datos etiquetados (posee respuestas correctas históricas).

- **Meta:** Predecir un resultado (Y) ante nuevos datos (X).
- **Ejemplo:** Scoring de crédito (Aprobado/Rechazado).

Aprendizaje No Supervisado

El modelo trabaja con datos sin etiquetar. Busca patrones, estructuras o relaciones ocultas.

- **Meta:** Agrupar u organizar los datos de forma lógica.
- **Ejemplo:** Segmentación de clientes (Clustering).

Por Refuerzo

Un agente aprende a tomar decisiones en un entorno dinámico mediante ensayo y error.

- **Meta:** Maximizar una recompensa acumulada a largo plazo.
- **Ejemplo:** Algoritmos de trading autónomo o ajedrez.

Aprendizaje Supervisado: Concepto Fundamental

- El aprendizaje supervisado es un paradigma de Machine Learning donde el modelo aprende de datos etiquetados.
- Proporcionamos al algoritmo ejemplos de entrada (variables predictoras, X) y sus correspondientes salidas deseadas (etiquetas, Y).
- El objetivo es aprender una función de mapeo $f(X) \approx Y$ para predecir la salida de nuevos datos no vistos.

Elementos del Aprendizaje Supervisado

- **Características (Features - X):** Las variables independientes o atributos de los datos. En finanzas: nivel de deuda, ingresos, edad.
- **Etiquetas (Labels - Y):** La variable dependiente o respuesta que queremos predecir. En riesgo: incumplimiento (1) o pago (0).
- **Modelo:** La estructura matemática que ajusta sus parámetros para mapear X a Y .

Clasificación vs. Regresión

Clasificación

- La variable objetivo Y es categórica (discreta).
- Ejemplo: Predecir si un cliente caerá en default (Sí/No).
- Algoritmos: Regresión Logística, SVM, Redes Neuronales (con salida Sigmoide).

Regresión

- La variable objetivo Y es continua (numérica).
- Ejemplo: Predecir el precio futuro de un activo (VaR).
- Algoritmos: Regresión Lineal, Árboles de Regresión.

Aprendizaje Supervisado: Concepto Fundamental

- El aprendizaje supervisado es un paradigma de Machine Learning donde el modelo aprende de datos etiquetados.
- Proporcionamos al algoritmo ejemplos de entrada (variables predictoras, X) y sus correspondientes salidas deseadas (etiquetas, Y).
- El objetivo es aprender una función de mapeo $f(X) \approx Y$ para predecir la salida de nuevos datos no vistos.

Elementos del Aprendizaje Supervisado

- **Características (Features - X):** Las variables independientes o atributos de los datos. En finanzas: nivel de deuda, ingresos, edad.
- **Etiquetas (Labels - Y):** La variable dependiente o respuesta que queremos predecir. En riesgo: incumplimiento (1) o pago (0).
- **Modelo:** La estructura matemática que ajusta sus parámetros para mapear X a Y .

Clasificación vs. Regresión

Clasificación

- La variable objetivo Y es categórica (discreta).
- Ejemplo: Predecir si un cliente caerá en default (Sí/No).
- Algoritmos: Regresión Logística, SVM, Redes Neuronales (con salida Sigmoide).

Regresión

- La variable objetivo Y es continua (numérica).
- Ejemplo: Predecir el precio futuro de un activo (VaR).
- Algoritmos: Regresión Lineal, Árboles de Regresión.

El Proceso de Aprendizaje

- ➊ **Alimentación:** Se introducen los datos (X, Y) al modelo.
- ➋ **Predicción Inicial:** El modelo genera una predicción $\hat{Y}$ usando parámetros aleatorios.
- ➌ **Cálculo del Error:** Se compara $\hat{Y}$ con Y mediante una función de pérdida (Loss Function).
- ➍ **Actualización:** El modelo ajusta sus parámetros internos para reducir el error.

- **Scoring de Crédito:** Evaluación probabilística del riesgo de contraparte.
- **Detección de Fraude:** Clasificación de transacciones como legítimas o fraudulentas en tiempo real.
- **Trading Algorítmico:** Predicción de movimientos de precios de activos basados en variables macroeconómicas.
- **Optimización de Portafolios:** Estimación de retornos esperados y volatilidades.

¿Qué pensamos cuándo escuchamos redes neuronales?

¿Qué pensamos cuándo escuchamos redes neuronales?





(g)



(h)

¿Qué pensamos cuándo escuchamos redes neuronales?



Inspiración Biológica: La Neurona

- Las Redes Neuronales Artificiales (ANN) se inspiran vagamente en el cerebro humano.
- **Dendritas:** Reciben señales (Inputs).
- **Soma:** Procesa la información (Suma ponderada).
- **Axón:** Transmite la señal de salida mediante una Función de Activación.
- El aprendizaje biológico ocurre al fortalecer las conexiones sinápticas (Pesos).

1943: El Modelo de McCulloch-Pitts

- Warren McCulloch y Walter Pitts proponen el primer modelo matemático de una neurona.
- Era un modelo binario: la neurona podía estar "encendida" o "apagada".
- Sumaba entradas ponderadas y usaba una función de paso rígida.
- Limitación: Los pesos debían configurarse manualmente.

1958: El Perceptrón de Rosenblatt

- Frank Rosenblatt introduce el **Perceptrón**, capaz de aprender iterativamente.
- Implementado en hardware (Mark I Perceptron) para reconocimiento visual simple.
- Ajustaba los pesos automáticamente basándose en el error.
- Generó expectativas desmedidas en la comunidad científica.

1969: La Caída del Perceptrón (El Problema XOR)

- Marvin Minsky y Seymour Papert publican *Perceptrons*.
- Demostraron que un Perceptrón de una capa solo resuelve problemas linealmente separables.
- No podía aprender funciones lógicas básicas como XOR.
- Conclusión: Se necesitaban redes multicapa, pero no había cómo entrenarlas.

Los Años 70: El Primer Invierno de la IA

- La publicación de Minsky y Papert causó un colapso en la financiación.
- DARPA y empresas retiraron el apoyo a redes neuronales.
- La atención pasó a los "Sistemas Expertos" (IA Simbólica).
- La investigación en ANN quedó estancada.

1986: El Renacimiento con Backpropagation

- Rumelhart, Hinton y Williams popularizan **Retropropagación (Backpropagation)**.
- Resolvió el problema del Perceptrón: permitía entrenar Perceptrones Multicapa (MLP).
- **Mecanismo:** Calcula el gradiente del error en la salida y lo propaga hacia atrás, ajustando los pesos mediante la regla de la cadena.

Redes Neuronales Multicapa (MLP)

- **Capa de Entrada:** Recibe las variables.
- **Capas Ocultas:** Extraen características y relaciones no lineales.
- **Capa de Salida:** Emite la predicción final.
- Teorema de Aproximación Universal: Una red con una capa oculta puede aproximar cualquier función continua.

Los Años 90 y 2000: El Segundo Invierno

- **Desvanecimiento del Gradiente:** En redes profundas, la señal de error se diluía.
- **Falta de Datos:** No había bases de datos masivas.
- **Poder Computacional:** Las CPUs eran demasiado lentas.
- Support Vector Machines (SVM) dominaron el área.

2012+: La Revolución del Deep Learning

- **Big Data:** Explosión de datos digitales.
- **Hardware (GPUs):** Paralelización masiva de matrices.
- **Innovación Algorítmica:** Nuevas funciones (ReLU).
- Hito: La red convolucional AlexNet arrasa en ImageNet (2012).

Las Redes Neuronales en el Presente Financiero

- Núcleo de la IA financiera y análisis cuantitativo.
- Uso de RNN/LSTMs para series de tiempo financieras.
- Uso de Transformers (LLMs) para análisis de sentimiento en mercado.
- De modelos experimentales a herramientas core en gestión de riesgo.

El Flujo de Trabajo en Modelado Predictivo

- El desarrollo de un modelo es un ciclo estructurado:
- 1. Entendimiento del Negocio y Datos.
- 2. Preprocesamiento (Limpieza y Escalamiento).
- 3. División de Datos (Train y Test).
- 4. Entrenamiento del Modelo (Ajuste de Pesos).
- 5. Evaluación (Métricas de Desempeño).
- 6. Despliegue.

Preprocesamiento: La Base del Éxito

- Las Redes Neuronales son muy sensibles a la calidad de los datos ("Garbage in, garbage out").
- **Imputación:** Tratar valores nulos o faltantes.
- **Codificación:** Convertir variables categóricas (One-Hot Encoding).
- **Outliers:** Tratamiento de valores extremos que distorsionan los gradientes.

Transformación y Escalamiento de Variables

- Los gradientes convergen mejor si las características están en una escala similar.
- **Min-Max Scaling:** Comprime al rango $[0, 1]$.

$$X_{scaled} = \frac{X - X_{min}}{X_{max} - X_{min}}$$

- **Estandarización (Z-score):** Centra en 0, desviación estándar 1.

La Partición Fundamental: Evitar la Memorización

- Es crítico no evaluar el modelo con los datos que usó para aprender.
- Un modelo puede memorizar y fallar en predecir datos nuevos.
- Solución: Dividir el dataset en subconjuntos mutuamente excluyentes antes de modelar.

El Conjunto de Entrenamiento (Train Set)

- **Propósito:** "Material de estudio" del modelo.
- **Proporción típica:** 70 % a 80 % de los datos históricos.
- El modelo ve las variables X y las etiquetas Y .
- El algoritmo ajusta iterativamente los pesos para minimizar el error en este conjunto.

El Conjunto de Prueba (Test Set)

- **Propósito:** Simular el mundo real (".Examen final").
- **Proporción típica:** 20 % a 30 % de los datos.
- El modelo recibe X_{test} y genera $\hat{Y}_{test}$. Los pesos están congelados.
- Se compara $\hat{Y}_{test}$ con Y_{test} para medir la capacidad de generalización.

El Conjunto de Validación

- A menudo se usa una tercera partición (ej. 60 % Train, 20 % Val, 20 % Test).
- **Propósito:** Evaluar iterativamente durante el entrenamiento para ajustar *hiperparámetros* (arquitectura, tasa de aprendizaje).
- Evita sesgar la arquitectura basándose en el Test Set.

El Peligro del Overfitting (Sobreajuste)

- El modelo es demasiado complejo y aprende el ruido” de Train.
- **Síntoma:** Excelente desempeño en Train, pésimo en Test.
- Ocurre por exceso de neuronas, capas, o iteraciones sin regularización.

Underfitting y Equilibrio Sesgo-Varianza

- **Underfitting:** El modelo es muy simple para captar patrones (ej. regresión lineal para datos no lineales). Mal desempeño en ambos conjuntos.
- **Alto Sesgo (Bias):** Suposiciones demasiado fuertes (Underfitting).
- **Alta Varianza:** Muy sensible al Train set (Overfitting).
- El objetivo es minimizar el error total equilibrando ambos.

Métricas de Evaluación: Matriz de Confusión

- En clasificación de riesgo, el Accuracy (% global) engaña en datos desbalanceados.
- **Verdaderos Positivos (TP):** Predijimos Default, fue Default.
- **Verdaderos Negativos (TN):** Predijimos Pago, fue Pago.
- **Falsos Positivos (FP):** Predijimos Default, pagó (Rechazo injusto).
- **Falsos Negativos (FN):** Predijimos Pago, hizo Default (Pérdida de capital).

- ¿Por qué usar Excel/Hojas de cálculo en clase?
- **Transparencia:** Abre la “caja negra”, mostrando cómo interactúan los pesos y funciones celda a celda.
- **Desmitificación:** Demuestra que una red es una serie de operaciones matriciales.
- Se usa el complemento **Solver** para realizar el ajuste de pesos (Backpropagation simplificado).

El Modelo en Excel: Datos y Arquitectura

- **El Objetivo:** Predecir el riesgo de crédito (0 = Pago, 1 = Default) basándonos en variables financieras, construyendo una red neuronal desde cero en celdas.
- **Pestañas 1 y 2 (Datos y Escalamiento):**
 - Tenemos 3 variables de entrada: Edad, Ingresos y ratio Deuda/Ingreso.
 - Aplicamos *Min-Max Scaling* para que todas las variables vivan entre 0 y 1. Esto es vital para que la función de activación no se sature.
- **Pestaña 3 (Train_NN) - La Estructura:**
 - Las celdas fijas en la parte superior representan la "memoria" de la red: los **Pesos (W)** y **Sesgos (B)**.
 - Construimos 2 neuronas ocultas y 1 neurona de salida usando fórmulas nativas de Excel para replicar la activación matemática: $=1/(1+EXP(-Suma_Ponderada))$.

El "Motor" de Aprendizaje: Solver como Backpropagation

- En la pestaña de Entrenamiento (*Train*), calculamos el error de cada predicción comparando el resultado de la neurona de salida con el valor real (Error Cuadrático).
- **La Celda Objetivo:** Al final de la tabla sumamos todos los errores. Esta celda representa nuestra *Función de Pérdida* (*Loss Function*).
- **El Algoritmo (Excel Solver):**
 - Usamos la herramienta Solver para simular el proceso de aprendizaje.
 - Le pedimos que **minimice** la celda del Error Total.
 - ¿Cómo lo logra? Dándole permiso para modificar iterativamente las celdas de los Pesos y Sesgos.
 - Al usar el método *GRG Nonlinear*, Excel aplica un algoritmo de gradiente descendente, ajustando las conexiones hasta encontrar los patrones en los datos.

- **Pestaña 4 (Test_NN):** Evalúa datos que la red *no vio* durante el entrenamiento. Sus celdas de pesos están congeladas” (vinculadas a la hoja Train). Sirve para comprobar que el modelo generaliza y no solo memoriza.
- **Pestaña 5 (Métricas de Evaluación):**
 - **Matriz de Confusión Interactiva:** Usa fórmulas condicionales. Si modificas manualmente la celda “Umbral de Decisión” (ej. de 0.5 a 0.3), verás cambiar los Falsos Positivos y Negativos en tiempo real.
 - **Métricas Derivadas:** Calcula Exactitud, Precisión, Recall y el F1-Score de forma automática basándose en la matriz.
 - **AUC-ROC Aproximado:** Mide el Área Bajo la Curva barriendo 10 umbrales distintos y calculando áreas mediante la suma de pequeños trapecios (Regla Trapezoidal).

Diseño de la Arquitectura Financiera en Excel

- **Problema:** Clasificación de Riesgo de Crédito (0 = Pago, 1 = Default).
- **Entradas (Capa 1):** 3 variables escaladas (Edad, Ingreso, Deuda).
- **Capa Oculta (Capa 2):** 2 neuronas ($H = \text{Sigmoide}(W_1 \cdot X + B_1)$).
- **Capa de Salida (Capa 3):** 1 neurona ($Y = \text{Sigmoide}(W_2 \cdot H + B_2)$).

- **Función Sigmoide:** $=1 / (1 + \text{EXP}(-\text{Suma_Ponderada}))$
- **Error Cuadrático:** $=(\text{Prediccion} - \text{Valor_Real})^2$
- **Error Total (Loss):** La suma de todos los errores cuadráticos del conjunto Train.

El Proceso de Entrenamiento con Solver

- ① Asignar valores iniciales (ej. -0.5 a 0.5) a los Pesos y Sesgos.
- ② Configurar Solver:
 - **Objetivo:** Minimizar Celda de Error Total.
 - **Cambiando Celdas:** Bloque de Pesos y Sesgos.
 - **Método:** GRG Nonlinear (Descenso de Gradiente).
- ③ Ejecutar y observar el ajuste de pesos y reducción del error.

- Una vez que Solver encuentra los pesos óptimos en la pestaña "Train", estos se congelan".
- Evaluamos la red en la pestaña "Test" aplicando los pesos encontrados a X_{test} .
- Si el Error en Test es similar al de Train, nuestro modelo generaliza correctamente el riesgo financiero.

Conclusiones y Siguietes Pasos

- Los árboles de decisión estructuran de forma gráfica y lógica las políticas comerciales de un banco.
- Pasar del diseño analítico en Excel al código en Python nos permite escalar estas reglas desde una matriz simple de 8 escenarios hasta millones de filas y múltiples combinaciones continuas.

¡Muchas gracias! ¿Preguntas?