

Ciencia de Datos para las Finanzas

Introducción a la Ciencia de datos para las Finanzas

César Núñez Cuevas
cnunezc@fen.uchile.cl



¿Cómo entra el Machine Learning acá?

¿Cómo entra el Machine Learning acá?



(c)



(d)

El Enigma de la “Caja Negra” en Modelos Predictivos

La Analogía del Cine: Mystery Boxes

Al igual que las *mystery boxes* de J.J. Abrams, donde el valor radica en el suspenso de lo desconocido, muchos algoritmos avanzados operan sin revelar su lógica interna.

- Ingresamos datos del cliente (Input).
- El modelo genera una predicción (Output).
- **El conflicto:** ¿Cómo confiamos en el resultado si la lógica intermedia permanece oculta en la oscuridad?

El Lado Oscuro del Riesgo

Un modelo sin interpretabilidad es como Darth Vader: posee un poder inmenso y toma decisiones drásticas, pero su criterio es hermético, inflexible y potencialmente peligroso frente a regulaciones bancarias (ej. leyes de no discriminación).

Abriendo la Caja: De la Caja Negra a la Caja Blanca

Para estudiantes y analistas de riesgo, el primer paso en Machine Learning no debe ser un modelo complejo y oculto, sino una estructura transparente.

Modelos de Caja Negra

- Redes Neuronales Profundas o Gradient Boosting.
- Alta precisión matemática.
- Explicabilidad casi nula para el auditor.

Modelos de Caja Blanca (Árboles)

- Reglas lógicas y secuenciales explícitas.
- Cada decisión de crédito deja un rastro auditable.

Los Tres Grandes Paradigmas del Machine Learning

El Machine Learning se clasifica principalmente en tres categorías, según la naturaleza de los datos y la forma en que el algoritmo interactúa con ellos:

Aprendizaje Supervisado

El modelo se entrena con datos etiquetados (posee respuestas correctas históricas).

- **Meta:** Predecir un resultado (Y) ante nuevos datos (X).
- **Ejemplo:** Scoring de crédito (Aprobado/Rechazado).

Aprendizaje No Supervisado

El modelo trabaja con datos sin etiquetar. Busca patrones, estructuras o relaciones ocultas.

- **Meta:** Agrupar u organizar los datos de forma lógica.
- **Ejemplo:** Segmentación de clientes (Clustering).

Por Refuerzo

Un agente aprende a tomar decisiones en un entorno dinámico mediante ensayo y error.

- **Meta:** Maximizar una recompensa acumulada a largo plazo.
- **Ejemplo:** Algoritmos de trading autónomo o ajedrez.

El Paradigma del Aprendizaje No Supervisado

- A diferencia del aprendizaje supervisado, aquí **no existen etiquetas** (Y) ni respuestas correctas predefinidas.
- El modelo se alimenta únicamente de características u observaciones (X) y debe encontrar la estructura subyacente por sí solo.
- **Objetivo principal:** Descubrir patrones ocultos, agrupaciones naturales o simplificar la representación de los datos.
- Es un proceso de "descubrimiento de la forma de los datos" más que de "predicción para corregir un error".

El Espacio Latente Financiero

- Los datos en finanzas (ej. ingresos, volumen de transacciones, edad, nivel de deuda) forman un espacio multidimensional complejo.
- El aprendizaje no supervisado busca topologías en este espacio: áreas de alta densidad de clientes y espacios vacíos.
- Asume una premisa clave: entidades (clientes, empresas, activos) con características financieras similares estarán "cerca" geométricamente en este espacio de datos.

Aplicaciones No Supervisadas en Finanzas

- **Segmentación de Clientes:** Crear perfiles de riesgo o comportamiento (ej. "Ahorradores Conservadores", "Gastadores de Riesgo") a partir de una base de datos sin clasificar previamente.
- **Detección de Anomalías (Fraude):** Identificar transacciones atípicas, viéndolas como puntos de datos que quedan aislados de cualquier clúster denso.
- **Diversificación de Portafolios:** Agrupar activos que muestran volatilidades correlacionadas a lo largo del tiempo, facilitando la dispersión del riesgo.

Los Retos Únicos del Aprendizaje Sin Etiquetas

- **Subjetividad y Sensibilidad Analítica:** No existe una única respuesta "correcta". Diferentes algoritmos y parámetros darán agrupaciones completamente distintas.
- **El Problema de la Evaluación:** Al carecer de la variable real contra la cual comparar, es imposible utilizar métricas tradicionales (Precisión, Recall, Exactitud).
- **Cuestiones de Preprocesamiento:** Métodos dependientes de la distancia geométrica como K-Means son extremadamente susceptibles a valores atípicos (outliers).

Precedentes y Orígenes (Años 50)

- Antes del auge de las computadoras modernas, los estadísticos ya buscaban de forma manual métodos de taxonomía numérica.
- El concepto teórico de minimizar la varianza intra-clúster (sumas de los cuadrados de los errores dentro de cada grupo) se discutía, pero era computacionalmente prohibitivo.
- Se necesitaba urgentemente un algoritmo iterativo que las primeras máquinas de procesamiento electrónico pudieran ejecutar con eficiencia.

1957: La Fundación por Stuart Lloyd

- Stuart Lloyd, notable investigador de Bell Labs, propuso el algoritmo base de lo que hoy conocemos popularmente como K-Means.
- **Un origen distinto:** Su objetivo no era el Machine Learning, sino la **Modulación por Impulsos Codificados (PCM)**.
- El algoritmo fue concebido para la cuantización de vectores, para comprimir señales continuas en niveles representativos discretos.
- Fue un reporte interno y su publicación formal no se dio sino hasta 1982.

1965: Edward Forgy y las Heurísticas

- De forma completamente independiente, Edward Forgy publicó un método heurístico virtualmente idéntico diseñado para el análisis multivariante.
- Forgy formalizó en la literatura la práctica de inicializar los "centros" (centroides) seleccionando aleatoriamente puntos de datos de la muestra.
- Hoy en día, la versión clásica y estándar de este algoritmo a menudo es nombrada con rigor académico como el **Algoritmo de Lloyd-Forgy**.

1967: James MacQueen y el Término "K-Means"

- James MacQueen es el investigador acreditado con acuñar formalmente el nombre compuesto "**K-Means**" en sus investigaciones.
- Su versión difería de Lloyd en un punto computacional crítico: MacQueen actualizaba los medios ("means") de forma continua. Cada vez que un único punto cambiaba de grupo, actualizaba el centro.
- Lloyd utilizaba un enfoque en "Batch" (lotes), moviendo los centroides sólo al término de reasignar toda la población (el enfoque usado hoy en día por eficiencia).

Evolución Hacia la Era Moderna: K-Means++ (2007)

- **La Debilidad del Clásico:** El algoritmo estándar inicializa los centroides al completo azar; esto lleva al algoritmo a quedar atrapado en resultados locales subóptimos.
- En 2007, David Arthur y Sergei Vassilvitskii publican **K-Means++**.
- Es un avance en la inicialización: asegura esparcir los primeros K centroides lo más distante y estratégicamente posible unos de otros antes de empezar la optimización.
- Revolucionó la estabilidad del modelo y es el estándar predeterminado hoy en día (ej. Scikit-learn).

Etapas 1: Selección Cuidadosa y Limpieza de Variables

- Los algoritmos basados en distancia sufren fuertemente de la *Maldición de la Dimensionalidad*. Agregar columnas irrelevantes distorsiona gravemente los agrupamientos.
- **Selección de Dominio en Finanzas:** Se requiere sentido de negocio para seleccionar características. Variables como Flujo Mensual o Nivel de Apalancamiento tienen alto valor.
- A nivel técnico, el K-Means estándar requiere vectores matemáticos **continuos y numéricos**. Introducir factores categóricos puros requiere adaptaciones (K-Modes).

Etapla 2: Preprocesamiento y Escalamiento Matemático

- El K-Means define "similitud" calculando directamente la distancia en una cuadrícula virtual.
- **Problema Grave:** Si medimos el "Monto de Depósitos" (en millones) frente al "Número de Tarjetas" (en unidades), la variable del monto dominará enteramente las distancias.
- El algoritmo asumirá de facto que la diferencia entre 2 y 5 tarjetas no es estadísticamente relevante diluida frente a diferencias de \$500,000 en saldos.

Etapa 3: Estandarización y Normalización

- Necesitamos transformar todas las columnas numéricas para que pesen de forma equitativa.
- **Escalamiento Min-Max (Normalización simple):**

$$X_{norm} = \frac{X - X_{min}}{X_{max} - X_{min}}$$


Comprime todas las distribuciones dentro del rango $[0, 1]$.

- **Estandarización (Z-Score):**

$$Z = \frac{X - \mu}{\sigma}$$

Re-centra los datos en el valor de 0 con desviación estándar 1. Muy recomendado si los datos financieros siguen distribuciones normales o hay valores extremos.


K-Means



Etapla 4: Configuración de la Semilla (Centroides)

- Un **Centroide** no es necesariamente un cliente real; es la coordenada abstracta y núcleo geométrico en el plano multidimensional que actuará como centro de atracción.
- Si predefinimos que deseamos buscar tres (3) perfiles financieros distintos, el algoritmo debe colocar $K = 3$ centroides iniciales.
- El éxito, rapidez y la configuración final del agrupamiento resultante están atados de manera importante a la posición de este "saque inicial" en el plano.

Centroides



Etapla 5: Medición (Distancia Euclidiana)

- ¿Bajo qué cálculo computa la máquina qué clientes comparten un comportamiento semejante? Empleando extensiones del Teorema de Pitágoras.
- La **Distancia Euclidiana**, la medida más corta en el espacio tradicional, computada entre un cliente P y el centroide C :

$$d(P, C) = \sqrt{(X_P - X_C)^2 + (Y_P - Y_C)^2 + \dots}$$

- El programa itera calculando la distancia de **cada cliente individual** hacia **cada uno** de los K centroides en el tablero.

Métricas Alternativas (Distintas Topologías)

- Si bien la variante clásica de K-Means opera bajo optimización Euclidiana, hay alternativas útiles en finanzas:
- **Distancia de Manhattan (L1 Norm):** Suma de las diferencias en valor absoluto de las coordenadas. Destacadamente menos influenciada ante valores atípicos severos.
- **Similitud del Coseno:** Analiza únicamente el ángulo formado entre dos perfiles, obviando la magnitud absoluta. Útil para entender "proporciones de gasto" sin importar si el cliente es millonario o de clase media.

Etapla 6: Expectation (La Asignación Inicial)

- Calculadas las distancias, el motor heurístico aplica una decisión lógica binaria por individuo.
- Cada punto del espacio de clientes es oficialmente etiquetado de manera provisional como perteneciente al clúster cuyo centroide resultó ser el de **distancia más cercana**.
- Esta acción, a nivel matemático, traza fronteras alrededor del plano creando **Diagramas de Voronoi**, asegurando la equidad territorial.

Etapas 7: Maximization (Actualización Aritmética)


- Agrupados los conjuntos de clientes, el centroide inicial ha perdido relevancia. Las dinámicas poblacionales del nuevo grupo le sobrepasan.
- **Actualización o Re-centralización:** El motor calcula la media exacta de cada vector/columna usando estrictamente solo a los clientes de dicho clúster.
- El centroide se teletransporta automáticamente para asentar su núcleo exacto en el nuevo centro de gravedad (baricentro).
- $$C_{nuevo} = \frac{1}{\text{población del clúster}} \sum_{cliente \in \text{clúster}} cliente$$

Etapas 8: Bucle y Convergencia

- Este poderoso proceso iterativo de (1) Mapear Distancias, (2) Reasignar Clientes, y (3) Trasladar el Centroide prosigue en un bucle continuo.
- Dictamina que la tarea ha concluido cuando documenta la **Convergencia Algorítmica**.
- Este estadio se alcanza bajo premisas como:
 - ① Ningún punto singular de datos requirió moverse a otro grupo distinto en la última iteración.
 - ② Los centroides reducen su desplazamiento por debajo de una tolerancia técnica.
 - ③ Se agota un cupo de iteraciones parametrizado (ej. 300 ciclos predeterminados).

El Enigma Principal en Clustering: Determinar "K"

- El K-Means opera a ciegas sobre directivas humanas. Si le exiges 3 perfiles de clientes, comprimirá a todos en 3 perfiles. Si le impones 10, fracturará el modelo forzando 10 perfiles.
- ¿Cómo calculamos un número óptimo y analíticamente justificable de segmentaciones sobre una cartera financiera no pre-explorada?
- A falta de un mecanismo con respuestas base correctas (etiquetas), debemos apoyarnos en métricas de índole interna y heurísticas visuales.



Line plot between K and inertia

La Inercia, Varianza, o Puntaje WCSS

- **WCSS:** *Within-Cluster Sum of Squares* (Suma Cuadrática Interna del Clúster).
- Representa el grado de compactación poblacional. Evalúa cuán densamente poblados y uniformes están los registros hacia el interior de un mismo clúster.
- Fórmula: Sumatoria sistemática iterando todos los clústeres, y luego cada observación asignada, sumando la métrica de distancia al cuadrado hacia su propio centroide.
- Minimizar la Inercia simboliza que los clientes dentro de un clúster son muy parecidos.

Complicaciones al Interpretar Librementemente WCSS

- Llegar a una Inercia de cero implica que hemos creado tantos clústeres exactos como individuos en nuestra cartera ($K = N$). El modelo sufre de sobreajuste crítico y nula escalabilidad.
- Es un mecanismo que decrecerá aritméticamente siempre que aumentemos marginalmente el parámetro K , tenga o no sentido de negocio.
- En lugar de buscar que WCSS sea cero absoluto, la usaremos para encontrar un punto clave de estabilidad financiera y pragmatismo del modelo.

Uso Diagnóstico Visual: El Método del Codo

- Es la metodología heurística estándar para seleccionar con rigor el hiper-parámetro K .
- Metodología Operativa:
 - ➊ Desplegar repetidamente rutinas separadas de K-Means parametrizando progresivamente $K = 1, 2, 3, \dots, 10$ grupos diferentes.
 - ➋ Tabular y retener el error cuadrático final (WCSS) devuelto por cada entrenamiento independiente.
 - ➌ Graficar una curva donde K controla el eje X, frente al decaimiento vertiginoso del WCSS en el eje Y.

Identificación Táctica del Punto del Codo

- En configuraciones iniciales (de $K = 1$ a $K = 2$ o 3), el desplome en la gráfica es brutal puesto que cada nuevo centroide captura varianza inexplorada.
- Al alcanzar un estadio específico en la gráfica, insertar un clúster extra deja de sumar retornos de homogeneización útiles y comienza a simplemente subdividir clústeres densos.
- Aquella bisagra o vértice de inflexión drástico en la pendiente (que se asemeja a un Codo.^aarticulado humano) delimitará estadísticamente el conjunto idóneo de clústeres.

Fallas Estructurales del Método de Decaimiento



- Las aplicaciones pragmáticas sobre Big Data financiero a menudo revelan un Çodo.^{ex}cesivamente alisado, difuso e impreciso.
- Ante estructuras superpuestas que no muestran centros hiper densos, resultará ambigua a la vista la tarea de confirmar lógicamente si $K = 3$ o $K = 4$ es mejor.
- Solución Complementaria: Recurrimos a los Índices Internos que evalúan la constante dualidad espacial entre Çohesión^{interna} vs "Separación.^{ex}terna.

Desarrollo del Índice "Silhouette Score"

- Puntaje validacional analizado y publicado científicamente por Peter J. Rousseeuw a fines del año 1986.
- Brinda una medición que evalúa no meramente cuán ajustado está un punto a su grupo directo; introduce a la aritmética un penalizador frente a la cercanía al grupo secundario alternativo (el clúster vecino más próximo).
- Usa una escala estandarizadora absoluta, posibilitando con efectividad comparar K-Means de $K = 3$ contra variaciones paramétricas como $K = 8$.

"Silhouette Score"

Silhouette analysis for KMeans clustering on sample data with $n_clusters = 5$



Decodificando un Reporte de Silhouette Score

- El modelo completo toma el macro promedio aritmético de cada $S(i)$. La métrica queda topada en un rango restrictivo entre **-1 y +1**.
- **Cercano a +1 absoluto:** Extraordinario modelado general. Puntos densamente compactados y abrumadoramente alejados del vecindario opuesto. Segmentos limpios.
- **Centrado alrededor de 0:** Representativo de márgenes confusos, solapamientos estadísticos severos. Puntos situados justo en las fronteras inter-centroides.
- **Sesgo negativo (Cercano a -1):** Denota una clasificación gravemente fallida; los puntos están matemáticamente mucho más emparentados al centro del vecindario opuesto que a sus pares teóricos.

Excel: Transparencia Pedagógica del Motor K-Means

- Entenderemos mejor K-Means abriendo sus fundamentos matemáticos. Resolveremos cada etapa manualmente en Microsoft Excel, revelando el funcionamiento interno del ciclo sin atajos computacionales de Python o R.
- Demostraremos iteraciones combinadas: Formulación de la Distancia Euclidiana, con una reasignación condicional usando funciones lógicas (MATCH y MIN).
- Ejecutaremos promedios relacionales (AVERAGEIF) para ubicar la actualización dinámica de centroides, tabulando finalmente métricas del Codo y Silueta en las celdas financieras.

Estructura General del Excel: De los Datos a las Iteraciones

Para desmitificar el aprendizaje no supervisado, el archivo `Excel KMeans Finanzas.xlsx` implementa el ciclo completo de K-Means celda por celda:

- **Pestañas 1 y 2 (Datos y Escalamiento):** Contienen una cartera simulada de clientes (Ingreso Anual vs. Frecuencia de Gasto) y su respectiva normalización Min-Max para evitar sesgos de magnitud.
- **Pestañas 3 y 4 (Iteraciones del Algoritmo):** Simulan el ciclo operativo de K-Means, separando la inicialización aleatoria de centroides de la actualización matemática por grupos.
- **Pestaña 5 (Métricas):** Centraliza la evaluación del modelo mediante el Método del Codo y las bases analíticas del Coeficiente de Silueta.

El Corazón Matemático: Distancias y Reasignación

En las pestañas de iteración del Excel, el cálculo geométrico se ejecuta de forma matricial mediante fórmulas nativas:

- **Distancia Euclidiana (SQRT):** Cada cliente evalúa su cercanía a los tres centroides iniciales (C_1, C_2, C_3) usando el Teorema de Pitágoras:

$$\sqrt{(X_{cliente} - X_{centroide})^2 + (Y_{cliente} - Y_{centroide})^2}$$

- **Asignación Automática (MIN y MATCH):** Las funciones determinan cuál de las tres distancias es la menor y le asignan al cliente el número de clúster correspondiente (1, 2 o 3) de forma completamente dinámica.

Actualización de Centroides y Evaluación (Codo y Silueta)

- **Paso de Maximización (AVERAGEIF):** En la cuarta pestaña, los centroides se "mueven" automáticamente calculando el promedio de las coordenadas de todos los clientes que quedaron asignados a su grupo en la iteración previa.
- **El Método del Codo (Inercia / WCSS):** La última pestaña tabula cómo disminuye la suma de distancias al cuadrado a medida que incrementamos el número de grupos (K).
- **Silhouette Score:** Explica visualmente cómo el Excel evalúa la tensión interna entre la *cohesión* ($a(i)$ dentro del grupo) y la *separación* ($b(i)$ frente al clúster vecino más cercano).