

Ciencia de Datos para las Finanzas

Introducción a la Ciencia de datos para las Finanzas

César Núñez Cuevas
cnunezc@fen.uchile.cl




Me Presento

- Mi nombre es César Núñez
- Ingeniero Comercial & Master en Finanzas de la Universidad de Chile.
- Master en Business Analytics & Big Data en MIP Politecnico di Milano.
- 6 años de experiencia como Analista de Riesgo Financiero en Bci, McKinsey y Tanner Servicios Financieros.
- Experiencia como profesor en la Universidad de Chile, Universidad Finis Terrae y en la Universidad Santo Tomás.



¿A quién no le ha pasado esto?



¿Qué es el Proceso de Originación?

Definición Operacional

La **originación de crédito** es el conjunto de etapas por las cuales pasa un cliente desde que manifiesta interés en un producto de financiamiento hasta que los fondos son desembolsados.

- Requiere un equilibrio crítico entre la **experiencia de usuario (UX)** (rapidez) y la **gestión del riesgo** (precisión).
- Históricamente basado en comités y reglas manuales; hoy automatizado a través de modelos analíticos.

Las Etapas de la Cascada de Crédito



La Oferta Pre-aprobada

- **Inversión del flujo:** En lugar de esperar a que el cliente pida un monto, el banco calcula de forma proactiva su capacidad antes del contacto.
- Genera estrategias de *cross-selling* efectivas en aplicaciones web y móviles.
- El éxito depende de un motor predictivo que asigne el **monto óptimo** sin disparar la tasa de default.

¿Cómo entra el Machine Learning acá?

¿Cómo entra el Machine Learning acá?



(c)



(d)

El Enigma de la “Caja Negra” en Modelos Predictivos

La Analogía del Cine: Mystery Boxes

Al igual que las *mystery boxes* de J.J. Abrams, donde el valor radica en el suspenso de lo desconocido, muchos algoritmos avanzados operan sin revelar su lógica interna.

- Ingresamos datos del cliente (Input).
- El modelo genera una predicción (Output).
- **El conflicto:** ¿Cómo confiamos en el resultado si la lógica intermedia permanece oculta en la oscuridad?

El Lado Oscuro del Riesgo

Un modelo sin interpretabilidad es como Darth Vader: posee un poder inmenso y toma decisiones drásticas, pero su criterio es hermético, inflexible y potencialmente peligroso frente a regulaciones bancarias (ej. leyes de no discriminación).

Abriendo la Caja: De la Caja Negra a la Caja Blanca

Para estudiantes y analistas de riesgo, el primer paso en Machine Learning no debe ser un modelo complejo y oculto, sino una estructura transparente.

Modelos de Caja Negra

- Redes Neuronales Profundas o Gradient Boosting.
- Alta precisión matemática.
- Explicabilidad casi nula para el auditor.

Modelos de Caja Blanca (Árboles)

- Reglas lógicas y secuenciales explícitas.
- Cada decisión de crédito deja un rastro auditable.

Los Tres Grandes Paradigmas del Machine Learning

El Machine Learning se clasifica principalmente en tres categorías, según la naturaleza de los datos y la forma en que el algoritmo interactúa con ellos:

Aprendizaje Supervisado

El modelo se entrena con datos etiquetados (posee respuestas correctas históricas).

- **Meta:** Predecir un resultado (Y) ante nuevos datos (X).
- **Ejemplo:** Scoring de crédito (Aprobado/Rechazado).

Aprendizaje No Supervisado

El modelo trabaja con datos sin etiquetar. Busca patrones, estructuras o relaciones ocultas.

- **Meta:** Agrupar u organizar los datos de forma lógica.
- **Ejemplo:** Segmentación de clientes (Clustering).

Por Refuerzo

Un agente aprende a tomar decisiones en un entorno dinámico mediante ensayo y error.

- **Meta:** Maximizar una recompensa acumulada a largo plazo.
- **Ejemplo:** Algoritmos de trading autónomo o ajedrez.

Concepto Core

Algoritmos que aprenden a partir de un conjunto de datos históricos que contiene tanto las características del cliente (**Features**) como el resultado real observado en el pasado (**Target** o Etiqueta).

$$Y = f(X) + \epsilon$$

Donde X representa el vector de características del solicitante e Y representa si pagó o entró en mora.

Componentes del Dataset en Crédito

Variables Predictoras (X - Features)

- Historial de comportamiento de pagos.
- Nivel de ingresos declarados.
- Nivel de endeudamiento consolidado.
- Estabilidad y antigüedad laboral.

Variable Objetivo (Y - Target)

- Variable Binaria (0 o 1).
- 1 = Crédito Aprobado / Buen Pagador.
- 0 = Crédito Rechazado / Cliente con Default.

Tipos de Problemas en el Modelado de Crédito

En nuestro flujo de originación conviven ambos enfoques:

- ① **Clasificación (Salida Cualitativa):** Determinar si el cliente califica o no para la oferta (**SÍ/NO**).
- ② **Regresión (Salida Cuantitativa):** Si el cliente es aprobado, determinar matemáticamente cuánta línea de crédito otorgar (**Monto asignado en \$**).

Para medir la capacidad real del modelo, dividimos de forma estricta los datos históricos:

- **Datos de Entrenamiento (Train):** Utilizados por el algoritmo para encontrar las reglas de segmentación y construir el árbol.
- **Datos de Validación/Test:** Datos retenidos que el modelo jamás ha visto. Sirven para comprobar si el árbol generaliza correctamente o si sufrió de *overfitting* (memorización).

El Peligro del Sobreajuste (Overfitting)

- Ocurre cuando un árbol crece demasiado y crea reglas tan específicas que solo funcionan para el set de entrenamiento.
- **Consecuencia financiera:** El modelo se vuelve incapaz de clasificar nuevos clientes del mercado real, subestimando el riesgo y provocando pérdidas por impagos.

Definición de las Variables en el Dataset

Para construir nuestro modelo en Python y Excel, analizamos 5 variables fundamentales:

Variable	Tipo	Descripción
Historial_Crediticio	Categórica	Comportamiento de pago previo (Bueno, Regular, Malo)
Nivel_Ingresos	Categórica	Rango salarial bruto mensual (Altos, Medios, Bajos)
Relacion_Deuda_Ingreso	Numérica	Porcentaje del salario destinado a pagar deudas actuales
Antigüedad_Laboral	Numérica	Años de permanencia en el trabajo actual
Monto_Solicitado	Numérica	Línea de financiamiento requerida por el cliente

Variable Core: Historial Crediticio e Ingresos

- **Historial Crediticio:** Es estadísticamente el predictor de riesgo más fuerte (medido por el indicador Gini en la industria). Refleja el *willingness to pay* (voluntad de pago).
- **Nivel de Ingresos:** Representa el *ability to pay* (capacidad financiera bruta). Define el tamaño potencial de la oferta.

Carga Financiera: Relación Deuda/Ingreso (DTI)

Fórmula Clave de Riesgo

$$\text{DTI} = \frac{\text{Total de Deudas Mensuales Consolidadas}}{\text{Ingreso Bruto Mensual}}$$

- Un DTI superior al 65 % indica que el cliente está financieramente sobrecargado, operando habitualmente como un criterio de rechazo directo.

- **Antigüedad Laboral:** Funciona como mitigador del riesgo de desempleo repentino. Estabilidad en el empleo reduce la variabilidad del ingreso.
- **Monto Solicitado:** Es la ancla comercial del modelo. El árbol debe evaluar si el monto solicitado guarda proporción lógica con el perfil de ingresos del cliente.

Definición de las Variables de Destino

El modelo entregará dos salidas estructuradas en cascada:


- **Salida 1: Oferta_Aprobada (SÍ/NO):** Clasificación binaria pura basada en la calidad del riesgo del cliente.
- **Salida 2: Monto_Preaprobado (\$):** Asignación analítica de la línea de crédito ajustada por capacidad y riesgo (Monto máximo vs. cupo básico).

La Lógica Secuencial de los Árboles

- Funciona mediante reglas de partición binaria recursiva.
- Comienza en un **Nodo Raíz** que selecciona la variable que aporta la mayor separación de riesgo.
- Se ramifica hacia **Nodos Internos** y culmina en **Nodos Hoja**, que dictan la predicción definitiva del perfil.

El Árbol de Decisión del Flujo de Crédito

Árbol de Decisión del Flujo de Crédito



¿Cómo decide el modelo dónde cortar la muestra?

El modelo utiliza criterios estadísticos de pureza matemática para elegir la variable óptima en cada paso:

- **Impureza de Gini:** Mide la probabilidad de clasificar incorrectamente un registro del set de datos. El algoritmo busca minimizar esta métrica en cada rama.
- **Entropía (Ganancia de Información):** Mide el desorden o la aleatoriedad de los datos. Buscamos nodos hijos lo más homogéneos (puros) posibles.

¿Por qué los Bancos usan Árboles de Decisión?

- **Explicabilidad Total (White Box):** A diferencia de las redes neuronales, es fácil explicar a un regulador o auditor el camino exacto que causó la denegación de un crédito.
- **Manejo de No-Linealidad:** Captura de forma nativa interacciones complejas entre variables categóricas y numéricas sin requerir transformaciones matemáticas avanzadas.

Limitaciones del Árbol Individual

- **Inestabilidad (Alta Varianza):** Pequeños cambios en los datos de entrenamiento pueden dar lugar a un árbol completamente diferente.
- Es por esto que en la producción avanzada de la industria se migra hacia ensamblados como *Random Forests* o *XGBoost*.

Matriz Logicial de Resultados

Historial	Ingresos	Deudas	Oferta Aprobada	Monto Pre-aprobado
Bueno	Altos	Bajas	SÍ	\$10.000.000 (Premium)
Bueno	Altos	Altas	SÍ	\$5.000.000 (Medio)
Bueno	Bajos	Bajas	SÍ	\$3.000.000 (Básico)
Bueno	Bajos	Altas	NO	\$0 (Rechazo por Carga)
Malo	Cualquiera	Cualquiera	NO	\$0 (Rechazo Político)

Determinación Analítica del Monto

El monto asignado no es aleatorio, responde a una función estructurada:

Lógica Algorítmica

$$\text{Monto} = f(\text{Riesgo Base}) \times \text{Capacidad de Pago Disponible}$$

Mitiga el riesgo de *Default* cortando la exposición del banco ante la combinación de variables desfavorables.

Traducción del Árbol a Fórmulas de Excel

Para estudiantes sin experiencia en código, las ramas se transforman directamente en funciones lógicas anidadas:

Fórmula para Oferta (Celda B10)

```
=SI(B5="Malo"; "NO"; SI(Y(B5="Bueno"; B6="Bajos"; B7=' 'Altas'); "NO"; "Sí"))
```

Fórmula para Monto (Celda B11)

```
=SI(B10="NO"; 0; SI(Y(B6=' 'Altos"; B7="Bajas"); 10000000; SI(Y(B6=' 'Altos"; B7=' 'Altas"); 5000000; 3000000)))
```

Desafíos y Limitantes en el Contexto Local (Chile)

La implementación de modelos predictivos en el sector financiero chileno enfrenta restricciones estructurales, técnicas y regulatorias complejas:

- **Marco Regulatorio y Ley de Datos Personales:** La actualización de la Ley N° 19.628 sobre protección de la vida privada exige un estándar estricto de consentimiento y limita el uso de ciertas fuentes de datos alternativas para el *scoring*.
- **Derecho a la Explicabilidad (Normativa CMF):** La Comisión para el Mercado Financiero (CMF) fiscaliza la gestión del riesgo de crédito. Los bancos deben ser capaces de auditar y explicar por qué un algoritmo rechazó una solicitud, lo que frena el uso de “cajas negras” puras.
- **Calidad y Fragmentación de Datos:** Integrar la información de los sistemas legados (*legacy systems*) de la banca tradicional con nuevas fuentes digitales (como datos transaccionales en tiempo real) representa un cuello de botella tecnológico mayor.
- **Sesgo Histórico y Exclusión Financiera:** Si los datos históricos de entrenamiento reflejan sesgos de subbancarización en ciertos segmentos de la población chilena, el modelo perpetuará la exclusión de forma automatizada.

Casos de Uso del Machine Learning en la Banca Nacional

A pesar de los desafíos, las instituciones financieras en Chile utilizan modelos supervisados y no supervisados para optimizar la rentabilidad y el control de riesgos:

Gestión de Riesgo y Operaciones

- **Originación Express:** Modelos de árboles y ensamblados para ofertas pre-aprobadas de consumo e hipotecarios en canales digitales (Apps/Web).
- **Prevención de Fraude:** Algoritmos en tiempo real que analizan las transacciones con tarjetas de débito/crédito y transferencias electrónicas (TEF).

Estrategia Comercial y Clientes

- **Modelos de Fuga (Churn):** Algoritmos predictivos que alertan cuando un cliente muestra patrones de desvinculación o baja transaccionalidad.
- **Cobranza Analítica:** Modelos que segmentan a los clientes en mora según su probabilidad de pago, optimizando los canales de contacto (SMS, mail, ejecutivo) y las provisiones requeridas.

Conclusiones y Siguietes Pasos

- Los árboles de decisión estructuran de forma gráfica y lógica las políticas comerciales de un banco.
- Pasar del diseño analítico en Excel al código en Python nos permite escalar estas reglas desde una matriz simple de 8 escenarios hasta millones de filas y múltiples combinaciones continuas.

¡Muchas gracias! ¿Preguntas?